Roya del café: sistema en cascada

Arquitectura, gráficas y auditoría de resultados

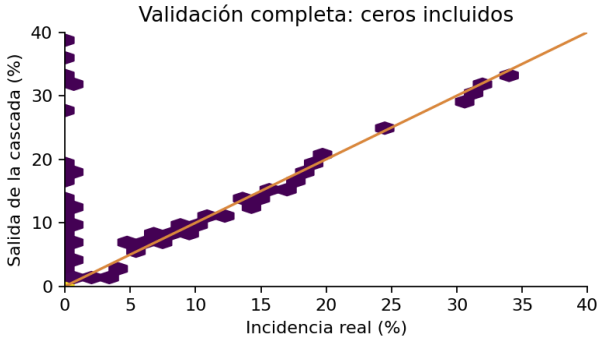
26 de octubre de 2026 | Versión 0.9 | Evaluación exploratoria

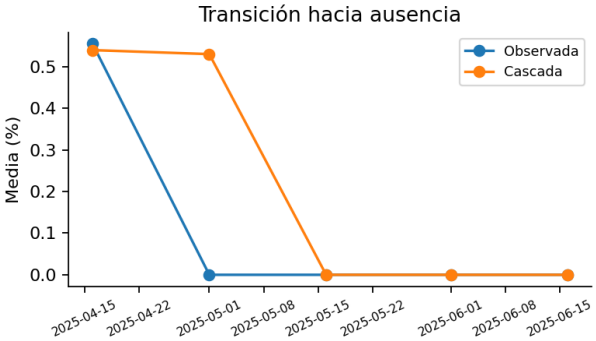
El sistema separa dos preguntas: **¿hay roya?** y, sólo ante presencia, **¿cuánta roya hay?** El detector aprende con ambas clases. El estimador de cantidad aprende exclusivamente con positivos reales, independientemente de los aciertos del detector.

Ámbito de validación	n	R^2	MAE (pp)
validacion_completa / cascada	12000	0.053	0.111
validacion_completa / persistencia	12000	-0.008	0.111
validacion_completa / cero	12000	-0.008	0.111
validacion_positivos / cantidad_condicional	199	0.995	0.306
validacion_positivos / persistencia	199	1.000	0.000

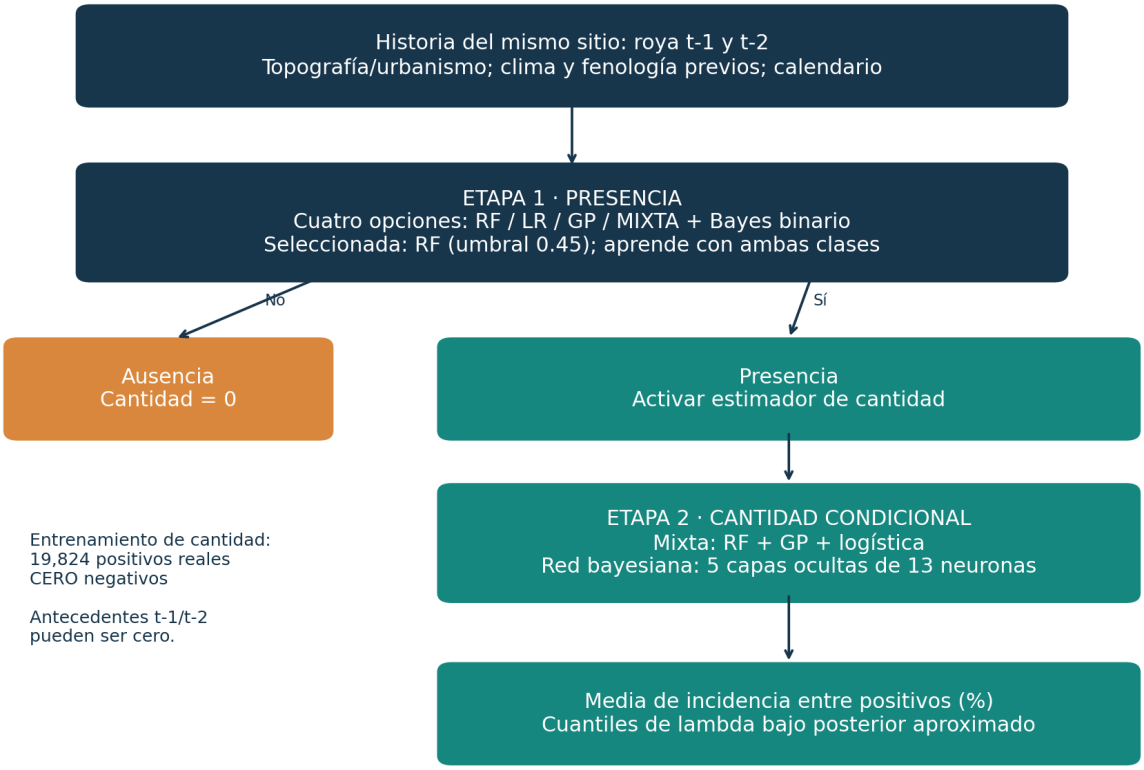
Conclusión: la cantidad condicional alcanza R^2=0.995 y MAE=0.306 entre 199 positivos; la cascada completa alcanza R^2=0.053 y MAE=0.111 al incluir los errores del detector. Persistencia tiene error cero entre esos positivos. Los resultados no demuestran superioridad operativa ni capacidad para anticipar una nueva temporada.

Unidad: porcentaje de incidencia. La pérdida de Poisson es una cuasipérdida para estimar una media positiva; no convierte los porcentajes en conteos de hojas. Los cuantiles corresponden a lambda bajo un posterior variacional aproximado, no a intervalos predictivos calibrados de las observaciones.





Arquitectura y flujo de ejecución



Cuatro alternativas en presencia: RF usa tres bosques; LR, tres regresiones logísticas; GP, tres modelos de programación genética; MIXTA combina una vista de cada familia, elegida por log-loss OOF de entrenamiento. Cada opción tiene su propio mezclador bayesiano binario y umbral. El panel y la entrada Excel permiten elegirlas; Automático conserva RF. La elección del detector es independiente de la cantidad. Las matrices de las cuatro se presentan en las páginas 5 y 6.

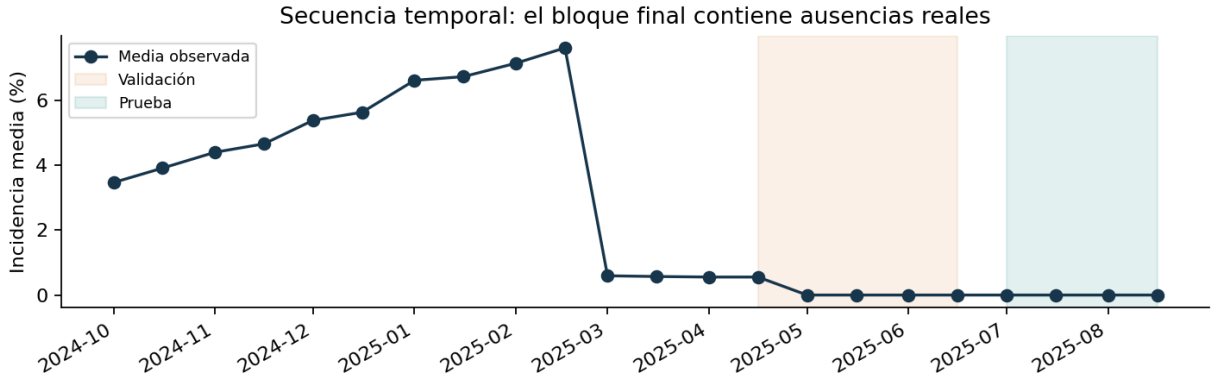
Entrenar cantidad con Y>0 estima la media condicional E[Y | Y>0, historia]. El filtrado se hace con la presencia real observada, no con los positivos predichos por el detector. Así se conservan casos difíciles que el detector podría omitir.

Al predecir: detector negativo implica salida operativa cero y no se ejecutan expertos de cantidad ni red bayesiana. Detector positivo activa el segundo sistema. Los antecedentes t-1 y t-2 pueden ser cero; se conservan para representar aparición de enfermedad.

Componente	Selección temporal
Presencia	RF: tres vistas y calibrador bayesiano binario. Umbral 0.45 elegido por equilibrio de FPR y FNR en validación.
Cantidad	MIXTA + 5 capas ocultas de 13 neuronas. Una vista de cada familia RF/GP/LR, elegida por log-loss OOF; cantidad elegida por MAE de positivos de validación.

Protocolo temporal y aumento

Bloque	Periodo	Fechas	Filas	Positivos
Entrenamiento	2024-10-01 a 2025-04-01	13	31200	19824
Validación	2025-04-16 a 2025-06-16	5	12000	199
Prueba	2025-07-01 a 2025-08-16	4	9600	0

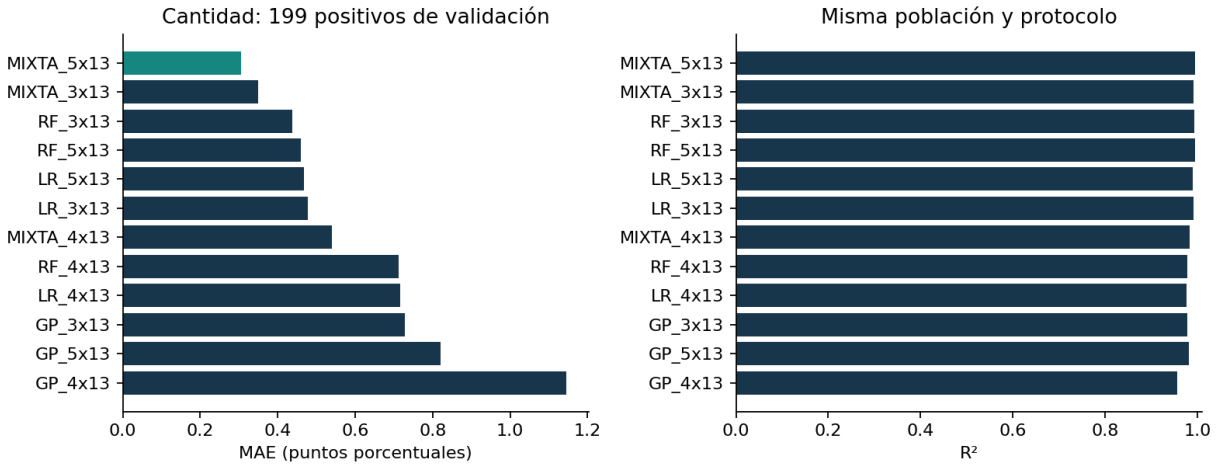


Son 2,400 series por municipio, parcela y coordenadas. Se excluyen las dos primeras observaciones sin historia completa; quedan 22 momentos. Los cortes 13/5/4 aproximan 60/20/20 sin dividir fechas (59.1/22.7/18.2%). Los ceros finales son ausencias reales confirmadas por el usuario.

Cinco ventanas expansivas generan predicciones fuera de muestra: cada bloque se predice con fechas estrictamente anteriores. La cantidad utiliza 19,824 positivos de entrenamiento y 14,483 positivos OOF para el mezclador. Las imputaciones y ACP de sus expertos se ajustan sólo con positivos train.

El aumento repite bloques observados únicamente dentro de entrenamiento. No fabrica climas ni nuevos individuos independientes. La red bayesiana se ajusta con OOF original, sin convertir duplicaciones en evidencia adicional. Probabilidades en escala 0 a 1; sólo rezagos/calendario se estandarizan. El horizonte es un muestreo adelante con antecedentes reales actualizados, no pronóstico recursivo de todo el bloque.

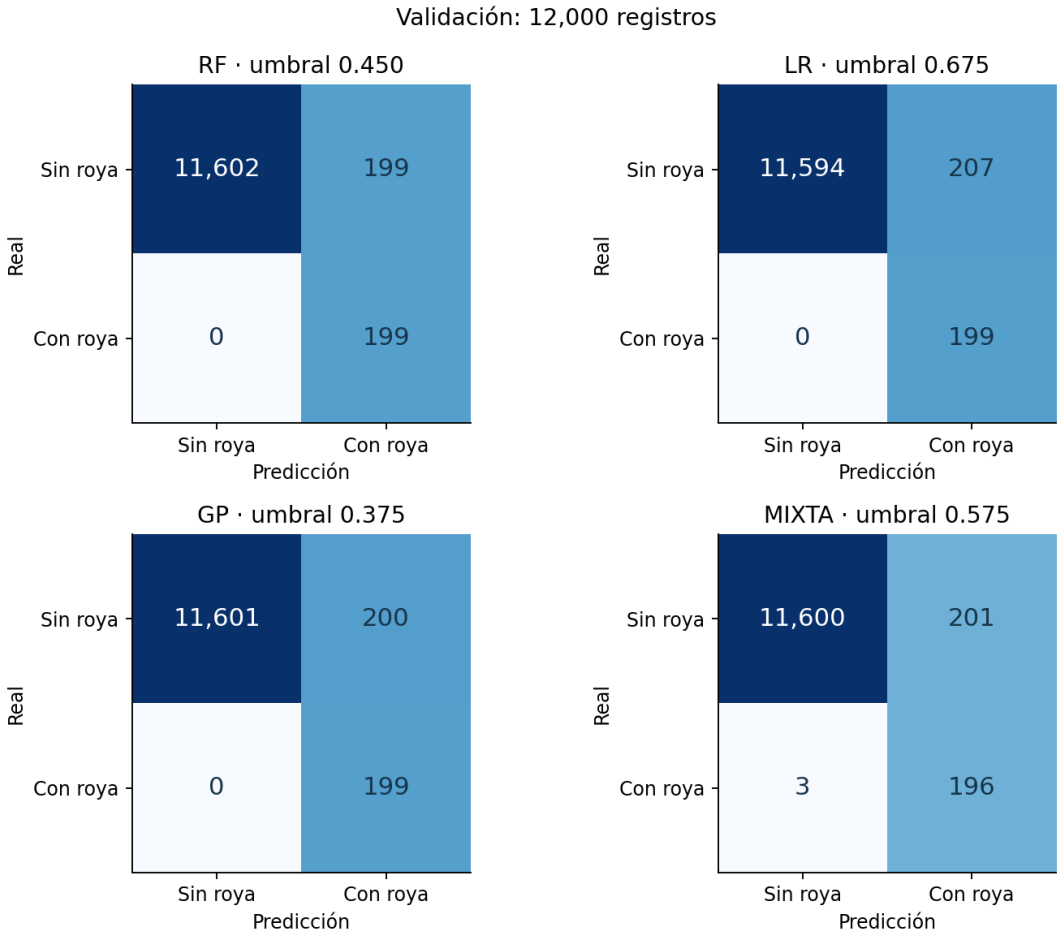
Comparación de las doce variantes



Expertos / capas ×13	MAE (pp)	R²	RMSE (pp)
RF_3x13	0.439	0.994	0.559
RF_4x13	0.713	0.978	1.052
RF_5x13	0.459	0.994	0.533
LR_3x13	0.477	0.991	0.656
LR_4x13	0.716	0.977	1.072
LR_5x13	0.467	0.989	0.724
GP_3x13	0.729	0.978	1.046
GP_4x13	1.146	0.956	1.480
GP_5x13	0.821	0.981	0.964
MIXTA_3x13	0.349	0.992	0.640
MIXTA_4x13	0.541	0.984	0.900
MIXTA_5x13	0.306	0.995	0.486

Las tres profundidades tienen 13 neuronas en cada capa oculta. Se aprende una distribución normal diagonal aproximada para todos los pesos y sesgos; salida exponencial para la media. Se utiliza un objetivo variacional cuasi-Poisson más KL. Los doce candidatos comparten particiones, rezagos, semillas y protocolo. La prueba final no elige arquitectura.

Matrices de confusión: validación

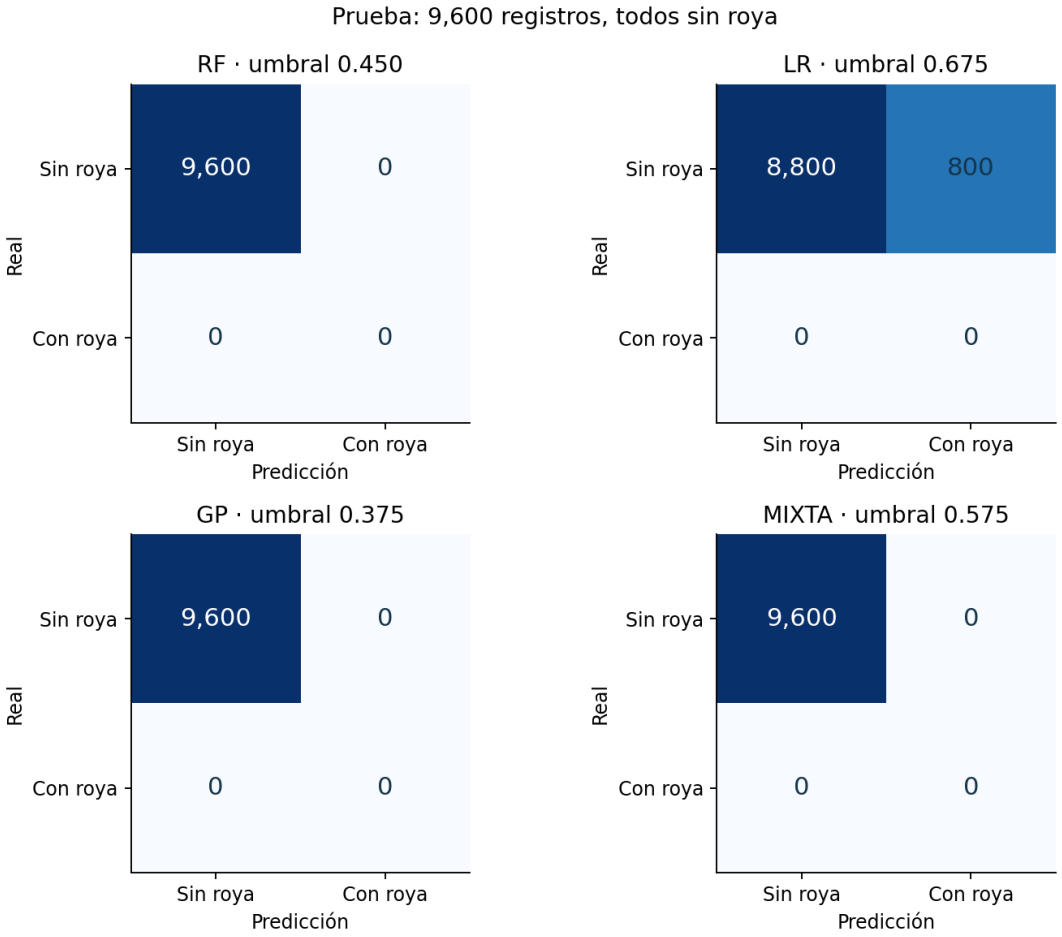


Las cuatro arquitecturas se evalúan sobre las mismas 12,000 observaciones: 199 con roya y 11,801 sin roya. Cada una conserva el umbral seleccionado por FPR+FNR en validación. Filas reales; columnas predichas. Color logarítmico, cifras absolutas.

Detector seleccionado RF: 199 verdaderos positivos, 199 falsos positivos, 0 falsos negativos y 11,602 verdaderos negativos. Sensibilidad=100% y especificidad=98.31% en este bloque. Los falsos positivos activan cantidad y se penalizan en la cascada completa.

Sistema	Validación MAE	Validación R^2
cascada	0.1110	0.0530
persistencia	0.1109	-0.0079
cero	0.1109	-0.0079

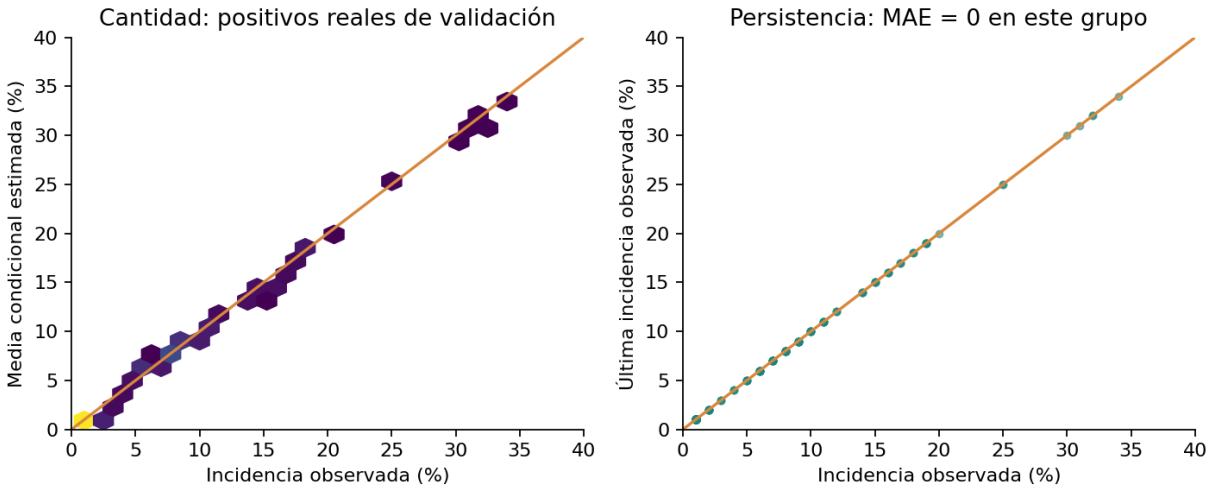
Matrices de confusión: prueba



Las 9,600 observaciones de prueba son ausencias reales. La sensibilidad no está definida: no hay positivos reales. Las matrices muestran falsas alarmas, pero no evalúan detección de positivos ni severidad. RF, GP y MIXTA no generan falsas alarmas; LR genera 800 en este bloque.

Con RF como detector, la cascada y predecir siempre cero obtienen MAE=0; R^2 no definido. El detector histórico LR/ACP se conserva como referencia diagnóstica: su división por sitios no acredita pronóstico cronológico. La ruta temporal selecciona presencia y cantidad separadamente.

Cantidad, persistencia y límites

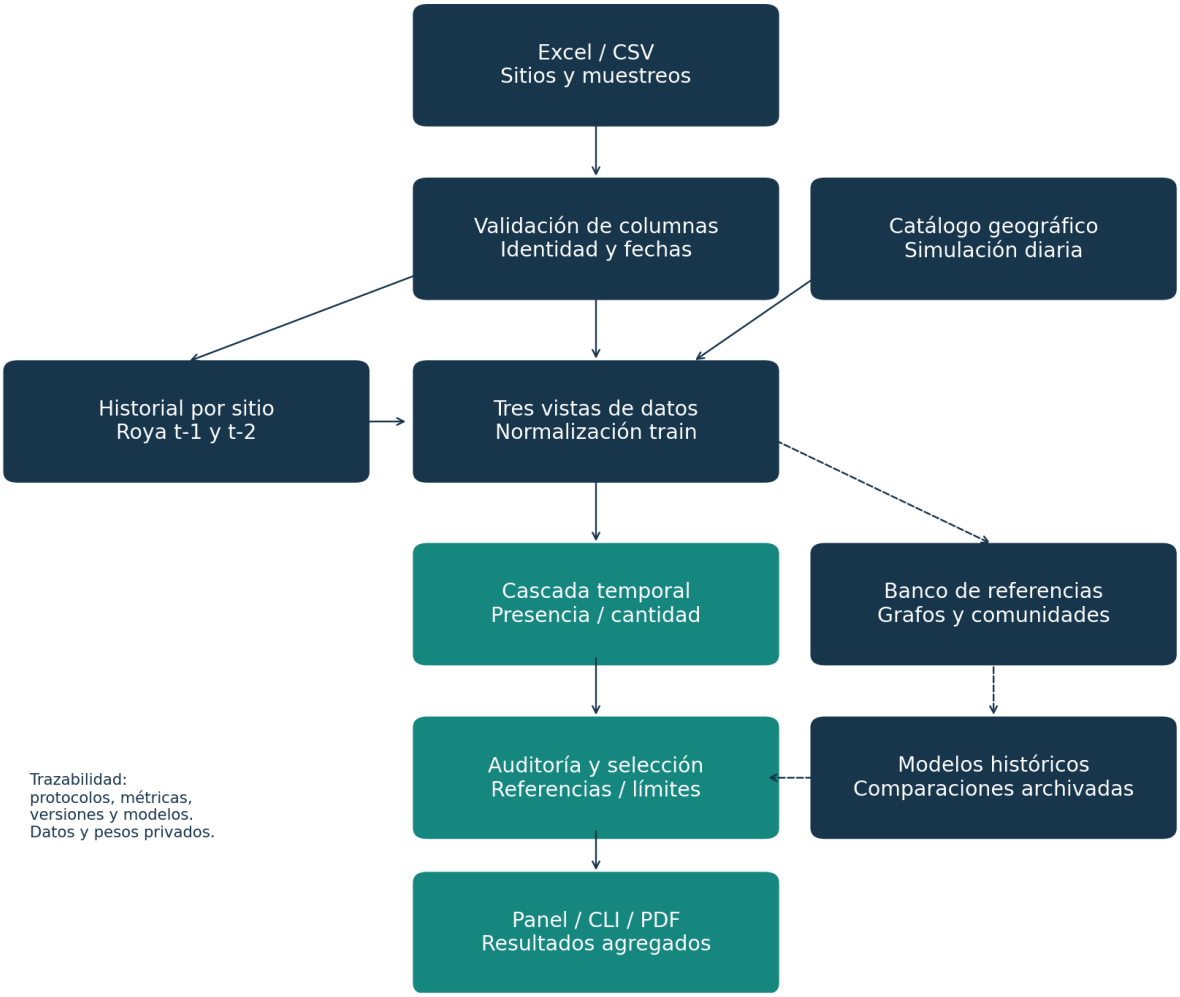


Los 199 positivos de validación tienen el mismo valor que su observación anterior: persistencia alcanza $R^2=1$ y MAE=0. La red seleccionada aproxima esa continuidad con error pequeño, pero todavía no añade valor frente a esa referencia en este grupo.

Rol de software	Acción y evidencia
Orquestador	Prepara presencia si falta, reentrena cantidad positiva y ejecuta la auditoría. Funciones Python reproducibles; no se afirma autonomía de agentes de lenguaje.
Entrenamiento	Expertos RF/GP/LR, aumento por bloques y OOF causal; compara redes de 3/4/5 capas de 13 neuronas.
Auditoría	Comprueba población positiva, orden temporal, reproducción independiente, puerta de ejecución y métricas con referencias. Conserva protocolos y resultados anteriores.
Reporte	Genera gráficas, tablas agregadas y este documento; no publica coordenadas, modelos ni predicciones por fila.

Límites pendientes: prueba histórica y validación reutilizadas durante la investigación; ausencia de positivos al final; humedad simulada diaria incompleta y simulación histórica no recalibrada temporalmente. Se necesita evaluar reaparición y cambios de intensidad en otra temporada. La auditoría mantiene **promoción operativa: no**.

Estructura del sistema completo



La ruta activa conserva historia, valida identidad y separa presencia de cantidad. El banco de referencias mantiene grafos y modelos anteriores para revisión. Sus grupos climáticos no se reutilizan automáticamente si incorporaron información de fechas futuras.

La entrada Excel actual permite ejecutar registros ya catalogados. La importación de observaciones inéditas es una ampliación distinta: debe incorporar mediciones, cobertura simulada y evaluación temporal antes de activar pronósticos nuevos.

Todo el sistema: módulos y estado

Módulo	Implementación y estado actual
Entrada de datos	Base histórica de 57,600 registros y 24 muestreos. Lectura CSV/XLSX; columnas, unidades, identidad y duplicados se validan. El nuevo archivo no modifica automáticamente el historial.
Geografía	Coordenadas, altitud, pendiente, orientación, relieve, distancias a agua/caminos/urbanización y comunidades estáticas. Hay 200 coordenadas con atributos contradictorios entre parcelas: se conserva identidad compuesta.
Simulación	365 días y 2,200 coordenadas. Temperatura/lluvia completas; humedad relativa diaria incompleta. La cobertura se comprueba y no se inventan ventanas ni se repite el año automáticamente.
Grafos	Capas topográfica, climática simulada y Excel; pesos de co-régimen, superposición y comunidades. Se conservan para análisis. Los grupos climáticos ajustados con todo el año no se incorporan sin reconstrucción causal a la ruta temporal.
Modelos históricos	Cuatro familias, regresiones lineales/logarítmicas/polinomiales/armónicas, GP, GAM, PIG y redes. Se conservan como referencias; no se comparan sus métricas con otra partición como si fueran el mismo experimento.
Ruta activa	Detección temporal con ambas clases; expertos de cantidad RF/GP/LR sólo positivos; mezclador bayesiano 3/4/5 capas de 13. Inferencia a un muestreo con historia real actualizada.
Orquestación	Funciones Python coordinan preparación, entrenamiento, selección, auditoría y reporte. Protocolos y resultados conservan trazabilidad. No hay agentes de lenguaje autónomos ni aprendizaje automático del orquestador.
Aplicación	Panel Streamlit, CLI, gráficas y PDF descargable. Código y agregados en GitHub; datos, coordenadas y pesos en paquete privado. Estado de uso: experimental, sin promoción operativa.

La separación entre módulos permite revisar errores sin borrar experimentos previos. Ampliar el catálogo o cambiar fuentes exige versionar datos, comprobar modelos y repetir evaluación; cargar un Excel no equivale a reentrenar.

Implantación con Excel de los mismos sitios

Habilitado hoy: cargar .xlsx o .csv con sitios y fechas ya catalogados. No es obligatorio incluir fila_excel: el sistema resuelve la identidad compuesta. Se reconocen acentos y separadores en nombres de columnas. Los datos suministrados se contrastan con el historial para evitar ignorar modificaciones.

Grupo	Columnas del contrato de entrada
Identidad	Municipio, Parcela, Coordenada_X, Coordenada_Y. Misma proyección y unidades del catálogo.
Tiempo	Mes_registrado con año y mes; Quincena 1 o 2. El modelo actual usa fechas aproximadas 1/16.
Clima real	Temperatura promedio, Punto_de_rocio, Temperatura, Humedad_especifica, Humedad_relativa, Precipitacion.
Fenología	Brotacion, Floracion, Amarre, Lechoso, Consistente, Maduro. Banderas independientes 0/1; pueden coexistir.
Respuesta	Incidencia de roya del Café puede estar vacía al solicitar predicción. Si se proporciona en una fecha histórica, los cambios se detectan y requieren importar/versionar la actualización.
Referencia	Altitud, orientación, variedades y datos cartografiados se recuperan del catálogo. Valores proporcionados que contradigan el registro se rechazan para su revisión.

Fechas nuevas: misma estructura y sitio no bastan. Se necesitan dos observaciones previas reales del mismo sitio, cobertura simulada en el origen y antecedentes requeridos, y una base actualizada/versionada. La ruta actual identifica y rechaza fechas fuera del catálogo; la importación de periodos inéditos y la extensión de la simulación permanecen pendientes. No se promete un pronóstico nuevo sólo por cambiar el mes del archivo.

Implantación local: instalar el paquete Python, configurar ROYA_DATA_DIR y ROYA_SIMULATION_NPZ con el paquete privado y ejecutar streamlit run app.py. También: roya predecir-excel entrada.xlsx salida.csv. La salida es CSV con presencia, probabilidad, cantidad e incertidumbre del modelo. Las primeras dos observaciones sin historia se conservan con estado de historia insuficiente y cantidad vacía; no se convierten en cero. Un servidor compartido requiere control de acceso a los datos privados; no se ha publicado un servicio externo.

Antes de uso operativo: importar periodos nuevos de forma controlada, extender simulación, evaluar una temporada con reaparición de roya y comparar con persistencia. El informe distingue funciones implementadas de requisitos pendientes.